Wnioskowanie Statystyczne II - Projekt

Magdalena Olbryś i Franciszek Grzonka

Pakiety których używamy:

```
library(dplyr)
library(ggplot2)
library(factoextra)
library(forecast)
```

Link do danych : https://www.kaggle.com/mirichoi0218/insurance

Dane i opis projektu

Zaczynamy od wczytania danych:

```
data <- read.csv('insurance.csv')
```

Dane zawierają informacje o 1338 osobach które wykupiły ubezpieczenie. Podzielimy je na zbiór uczący i testowy, postaramy się zbudować modele predykcyjne, a następnie na ich podstawie przewidzieć koszty leczenia(charges). Spróbujemy też ocenić który z nich jest najlepszy.

Dokładniej, wybierzemy najlepszy model wykorzystujący analizę wariancji, najlepszy model wykorzystujący regresje prostą i wieloraką oraz najlepszy model wykorzystujący analize kowariancji, a następnie je do siebie porównamy aby jak najlepiej przewidzieć ceny ubezpieczeń dla zbioru testowego.

Do wyboru modelu będziemy używać kryterium informacyjnego AIC, które estymuje informację traconą w skutek używania naszego modelu, a zatem będziemy wybierać model o jak najmniejszej wartości AIC.

Zmiennne

zmienna	opis
`age`	wiek ubezpieczonego
`sex`	płeć ubezpieczonego
`bmi`	wskaźnik masy ciała ubezpieczonego
`children`	liczba dzieci objętych ubezpieczeniem
`smoker`	indykator tego, czy ubezpieczony jest palaczem
`region`	region w USA w którym mieszka ubezpieczony
`charges`	indywidualne koszty leczenia rozliczane przez ubezpieczenie zdrowotne

Zobaczmy jak wygląda struktura danych:

```r
str(data)
```

```
## 'data.frame':    1338 obs. of  7 variables:
##  $ age     : int  19 18 28 33 32 31 46 37 37 60 ...
##  $ sex     : chr  "female" "male" "male" "male" ...
##  $ bmi     : num  27.9 33.8 33 22.7 28.9 ...
##  $ children: int  0 1 3 0 0 0 1 3 2 0 ...
##  $ smoker  : chr  "yes" "no" "no" "no" ...
##  $ region  : chr  "southwest" "southeast" "southeast" "northwest" ...
##  $ charges : num  16885 1726 4449 21984 3867 ...
```

Zmienne sex, children, smoker i region są kategoryczne a więc zmieńmy je na typ factor.

```r
data <- data %>% mutate(sex = factor(sex),
                        children = factor(children),
                        smoker = factor(smoker),
                        region = factor(region))
str(data)
```

```
## 'data.frame':    1338 obs. of  7 variables:
##  $ age     : int  19 18 28 33 32 31 46 37 37 60 ...
##  $ sex     : Factor w/ 2 levels "female","male": 1 2 2 2 2 1 1 1 2 1 ...
##  $ bmi     : num  27.9 33.8 33 22.7 28.9 ...
##  $ children: Factor w/ 6 levels "0","1","2","3",..: 1 2 4 1 1 1 2 4 3 1 ...
##  $ smoker  : Factor w/ 2 levels "no","yes": 2 1 1 1 1 1 1 1 1 1 ...
##  $ region  : Factor w/ 4 levels "northeast","northwest",..: 4 3 3 2 2 3 3 2 1 2 ...
##  $ charges : num  16885 1726 4449 21984 3867 ...
```

Przyjrzyjmy się dokładniej naszym danym.

```r
summary(data)
```

```
##       age            sex           bmi        children smoker
##  Min.   :18.00   female:662   Min.   :15.96   0:574    no :1064
##  1st Qu.:27.00   male  :676   1st Qu.:26.30   1:324    yes: 274
##  Median :39.00                Median :30.40   2:240
##  Mean   :39.21                Mean   :30.66   3:157
##  3rd Qu.:51.00                3rd Qu.:34.69   4: 25
##  Max.   :64.00                Max.   :53.13   5: 18
##        region       charges
##  northeast:324   Min.   : 1122
##  northwest:325   1st Qu.: 4740
##  southeast:364   Median : 9382
##  southwest:325   Mean   :13270
##                  3rd Qu.:16640
##                  Max.   :63770
```

W naszych danych mężczyzn i kobiet jest mniej więcej równa ilość, rozkład zamieszkania również jest dość równomierny prócz południowego wschodu gdzie przebywa trochę więcej osób, stosunek palaczy do osób niepalących wynosi mniej więcej 1 do 4.

```r
summary(data$age)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   18.00   27.00   39.00   39.21   51.00   64.00
```

```r
hist(data$age, 35, xlab = "Wiek", ylab = "Częstotliowść",  main = paste("Histogram wieku"))
```

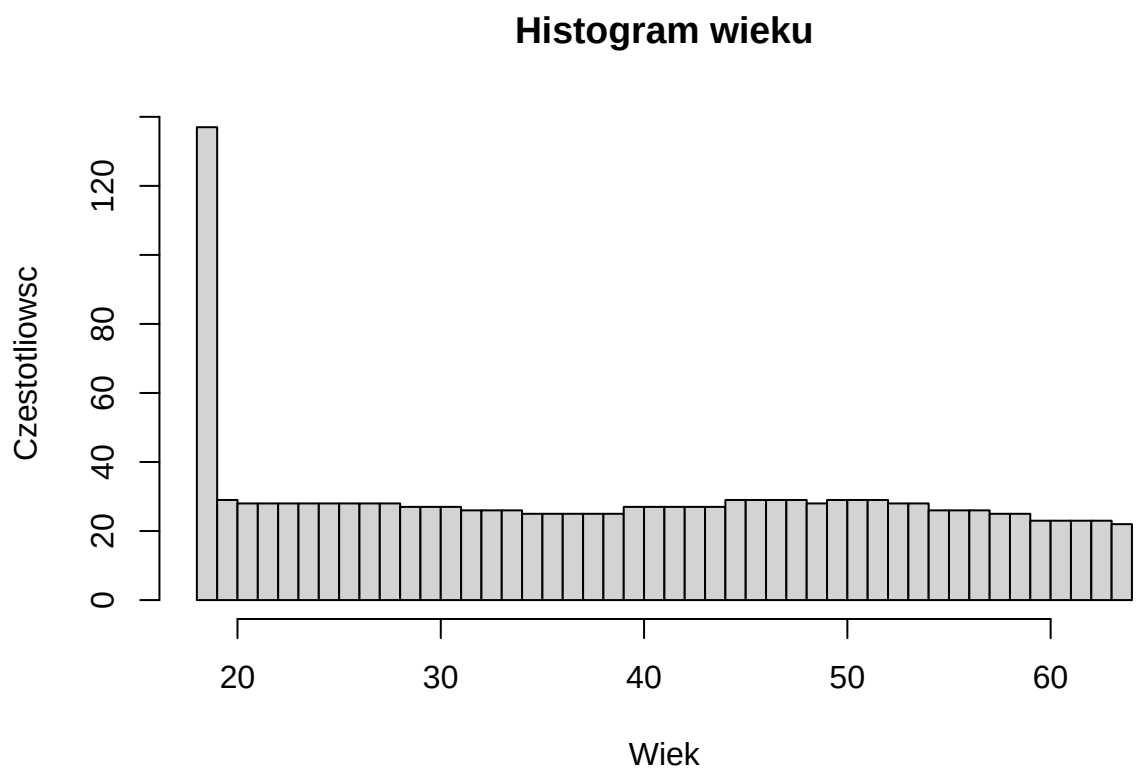

Widzimy, że wiek ubezpieczonych nie wykracza poza przedział 18-64 oraz pórcz dużej grupy osiemnastolatków ilość przedstaiwcieli każdej grupy wiekowej jest podobna.

```r
summary(data$bmi)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   15.96   26.30   30.40   30.66   34.69   53.13
```

```r
hist(data$bmi, 20, xlab = "BMI", ylab = "Częstotliowść",  main = paste("Histogram BMI"))
```

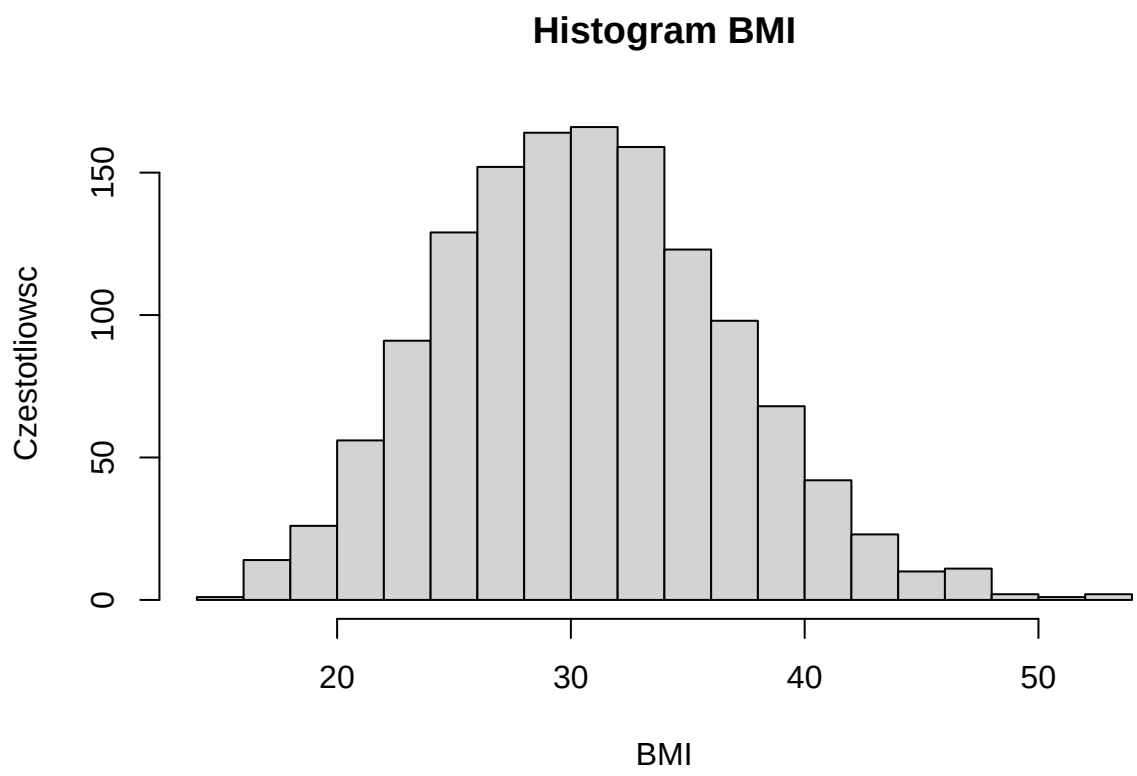

Wskaźnik BMI za to ma rozkład normalny, w kilkudziesięciu przypadkach jest większy od 40 co oznacza otyłość III stopnia oraz w kilkunastu przypadkach mamy do czynienia z niedowagą.

Jak widać w naszych danych nie występują wartości nierealistyczne, więc nie musimy czyścić danych ani zamieniać błędnych wartości.

Teraz podzielmy nasze dane na 2 zbiory: uczący i testowy.

```r
smp_size <- floor(0.66 * nrow(data))
set.seed(123)
train_ind <- sample(seq_len(nrow(data)), size = smp_size)
train <- data[train_ind, ]
test <- data[-train_ind, ]
```

Dalsze modele będziemy opierać na danych treningowych a predykcje tworzyć na danych testowych.

Klasyczna regresja

Porównajmy modele liniowe stworzone w oparciu o współczynniki które nie są kategorczyne(age i bmi).

```
model.age <-lm(formula = charges ~ age, data = train)
summary(model.age)
```

```
##
## Call:
## lm(formula = charges ~ age, data = train)
##
## Residuals:
##    Min     1Q Median     3Q    Max
##  -8482  -7181  -6059   5268  47721
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4924.44    1209.85   4.070 5.12e-05 ***
## age           221.05      29.03   7.613 6.87e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11940 on 881 degrees of freedom
## Multiple R-squared:  0.06173,    Adjusted R-squared:  0.06067
## F-statistic: 57.96 on 1 and 881 DF,  p-value: 6.872e-14
```

```
plot(model.age)
```

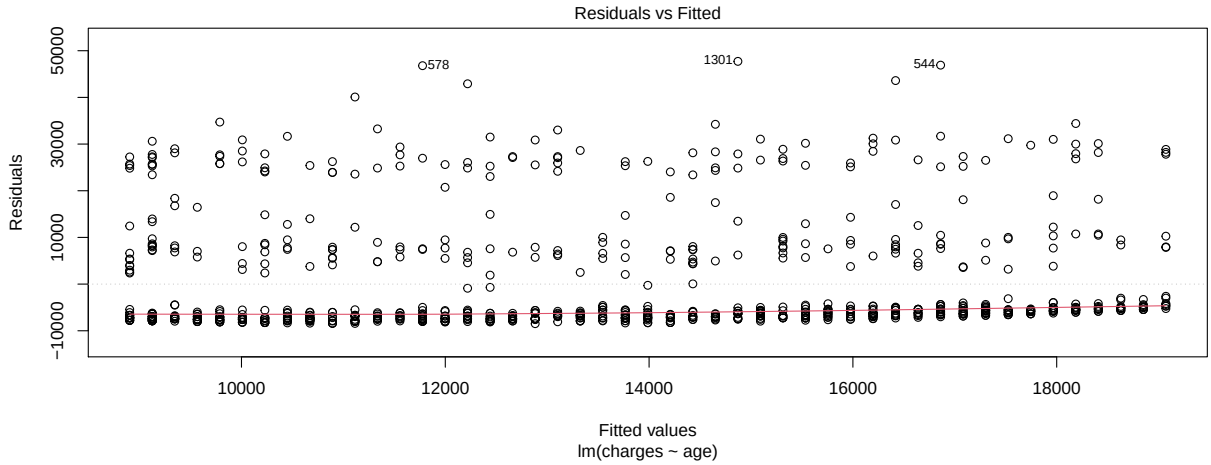

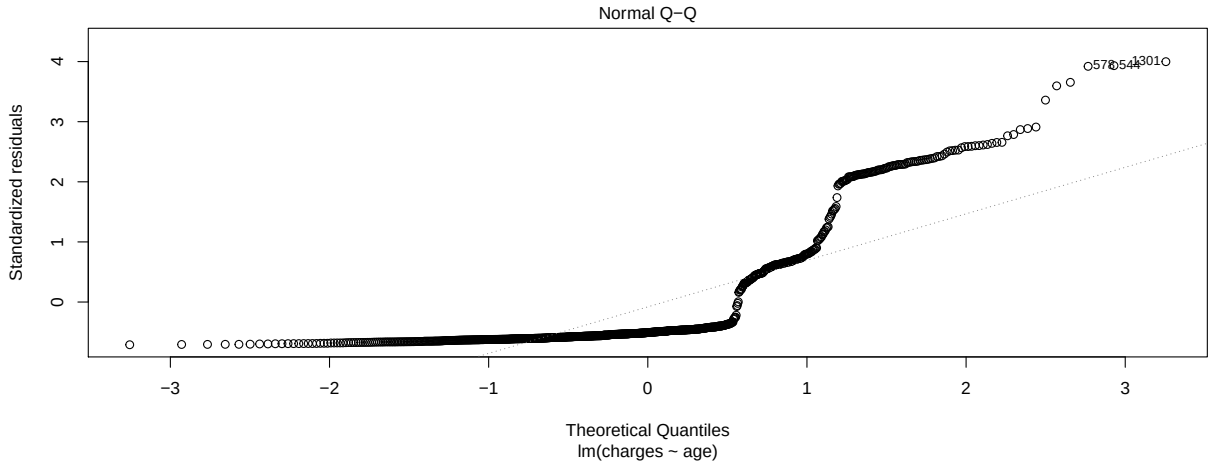

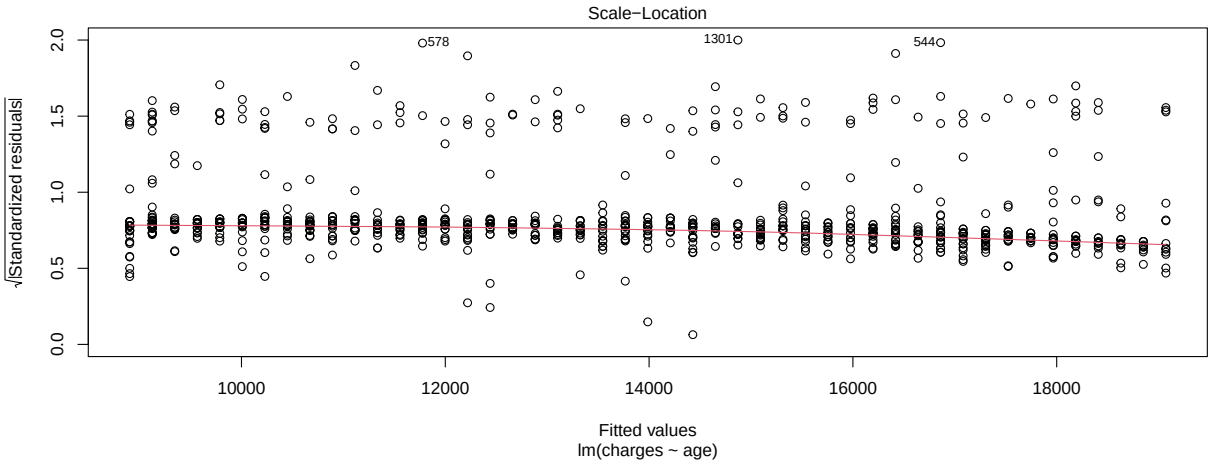

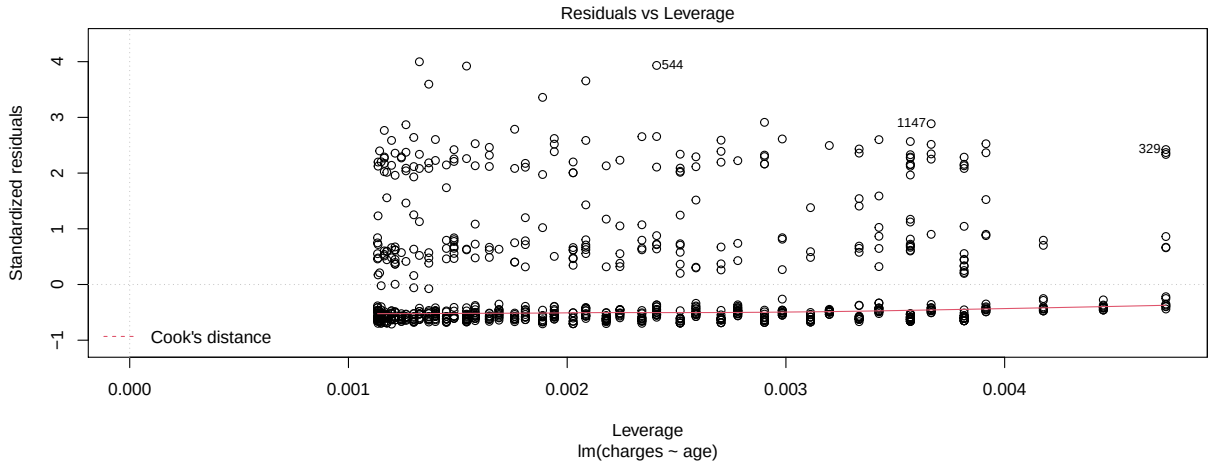

Niska wartość prawdopodobieństwa testowego pozwala nam stwierdzić, iż na podstawie współczynnika determinacji wiek wpływa na koszty zdrowotne tylko w około 6%.

Zobaczmy jak to wygląda dla modelu opartego na BMI.

```r
model.bmi <-lm(formula = charges ~ bmi, data = train)
summary(model.bmi)
```

```
##
## Call:
## lm(formula = charges ~ bmi, data = train)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -21191  -8288  -3905   4798  49179
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1493.24    2085.26   0.716    0.474
## bmi           392.65      66.26   5.926 4.46e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 12090 on 881 degrees of freedom
## Multiple R-squared:  0.03833,    Adjusted R-squared:  0.03724
## F-statistic: 35.11 on 1 and 881 DF,  p-value: 4.457e-09
```

```r
plot(model.bmi)
```

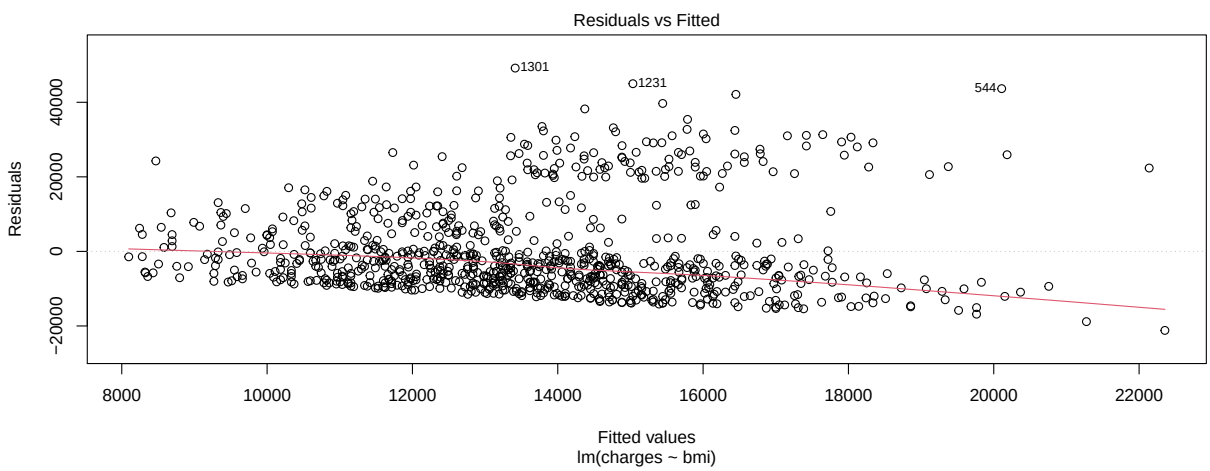

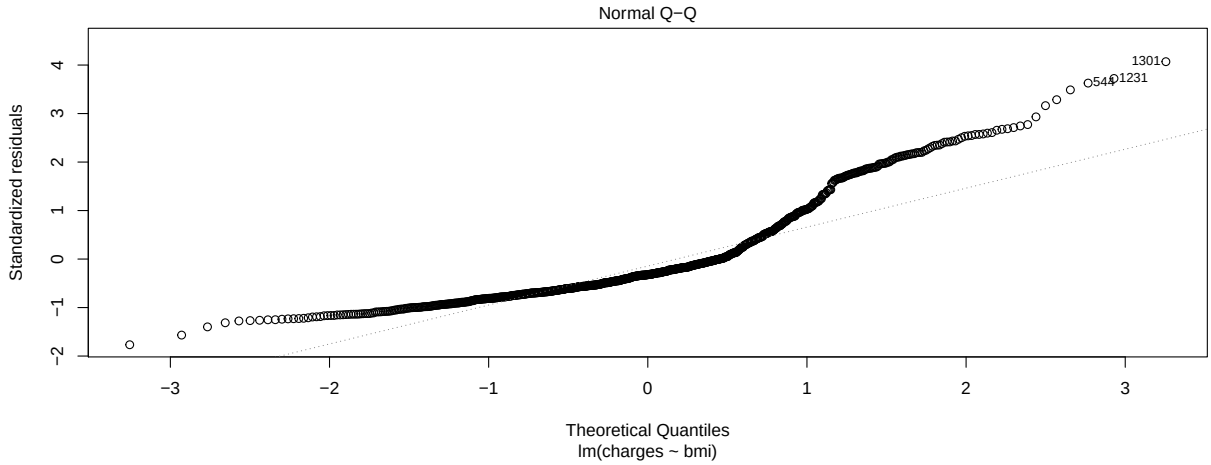

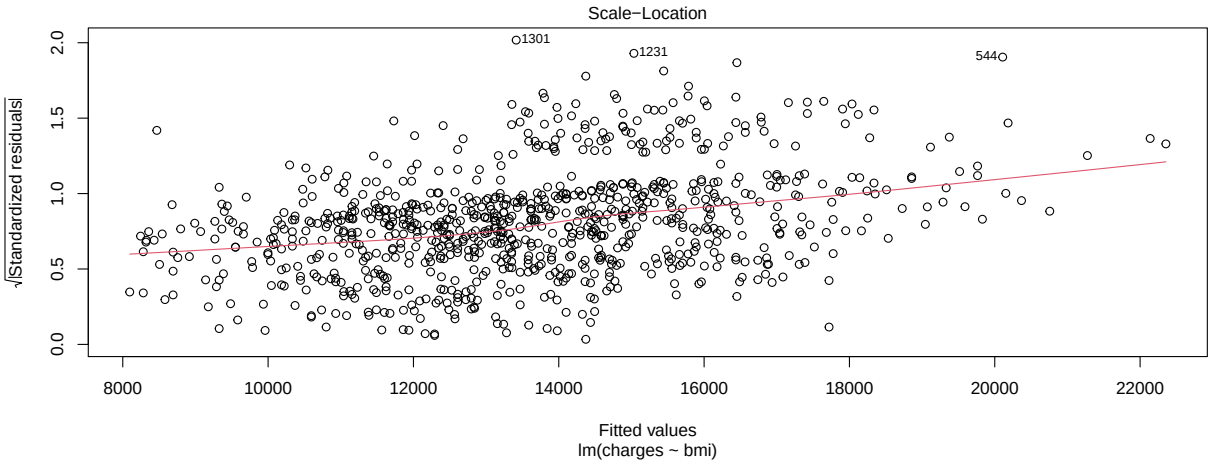

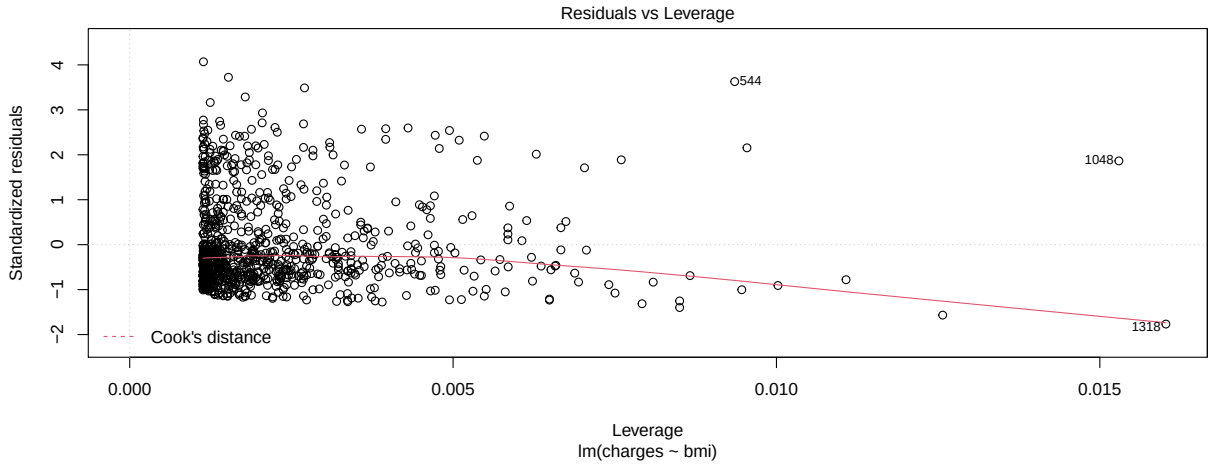

Widzimy, że wskaźnik masy ciała(bmi) wpływa na koszty leczenia tylko w 3,8%.

Stwórzmy model oparty na obu tych czynnikach.

```r
model.age_bmi <- lm(formula = charges ~ age + bmi, data = train)
summary(model.age_bmi)
```

```
##
## Call:
## lm(formula = charges ~ age + bmi, data = train)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -15877  -7257  -5247   7508  47975
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -5435.58    2241.34  -2.425   0.0155 *
## age           207.69      28.68   7.243 9.61e-13 ***
## bmi           352.67      64.64   5.456 6.35e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11750 on 880 degrees of freedom
## Multiple R-squared:  0.09243,    Adjusted R-squared:  0.09036
## F-statistic: 44.81 on 2 and 880 DF,  p-value: < 2.2e-16
```

```r
plot(model.age_bmi)
```

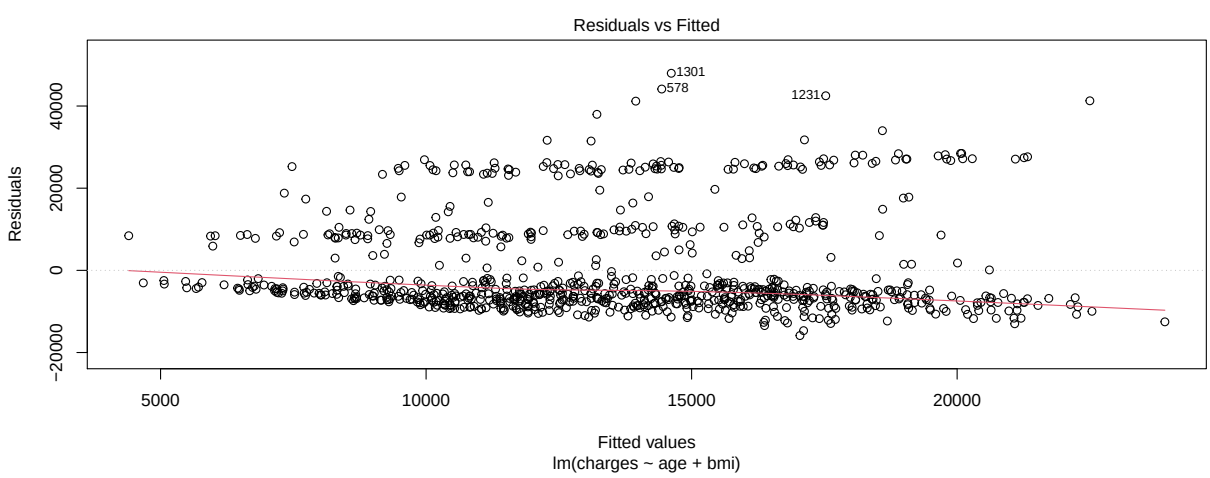

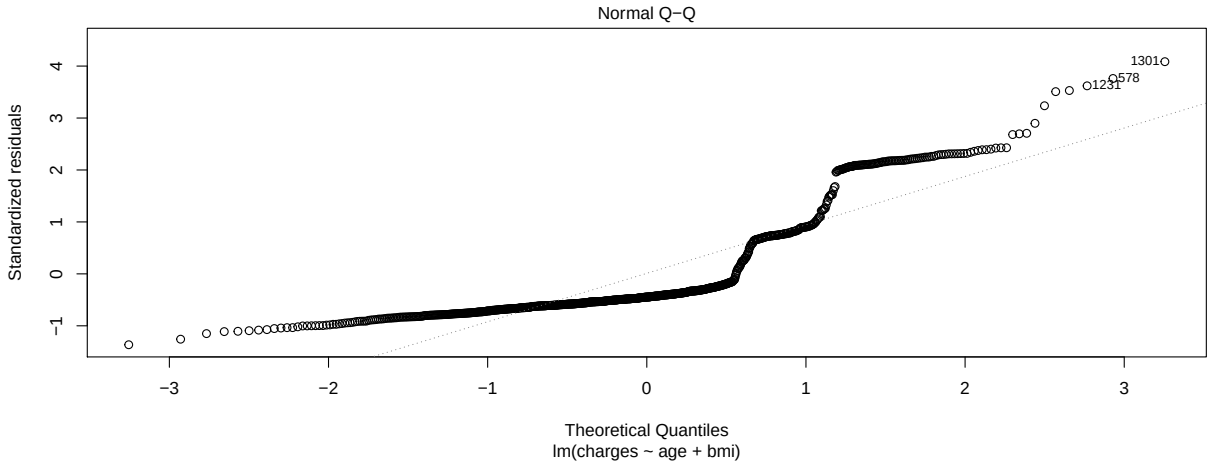

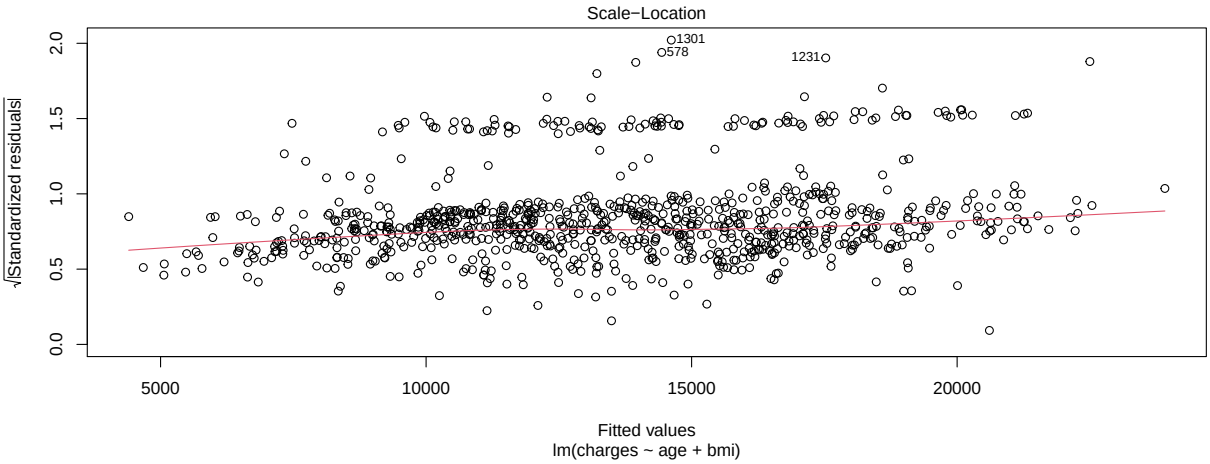

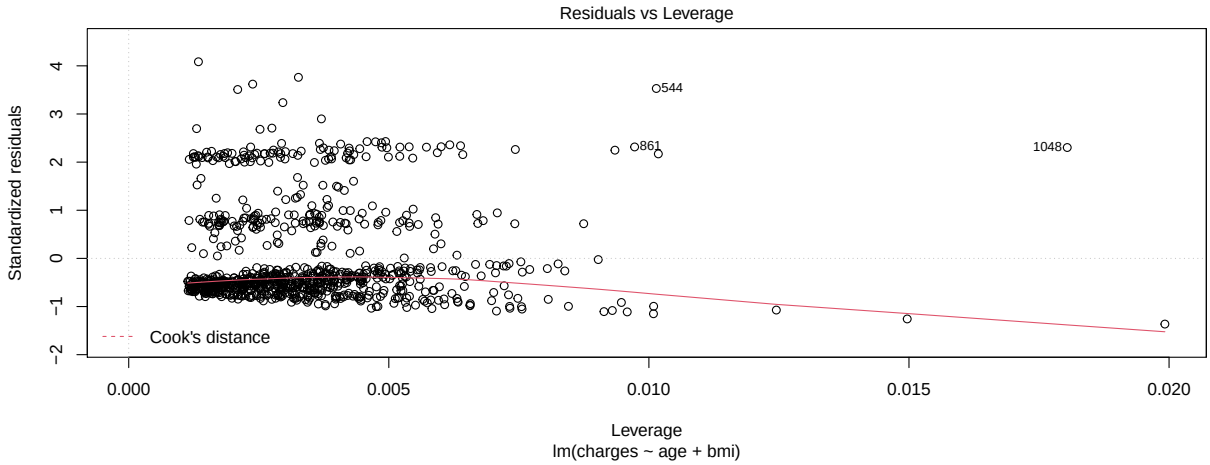

Możemy zauważyć że model zawierający zmienną wieku jaki bmi jest zdecydowanie lepszy od poprzedników opierających się na pojedynczych zmiennych. R kwadrat wynosi 9,2% co jak do tej pory jest najlepszym wynikiem.

Sprawdźmy to jeszcze porównując kryteria AIC.

```r
extractAIC(model.age)
```

```
## [1]     2.00 16581.03
```

```r
extractAIC(model.bmi)
```

```
## [1]     2.00 16602.78
```

```r
extractAIC(model.age_bmi)
```

```
## [1]     3.00 16553.66
```

Kryterium to potwierdza, ponieważ wynik dla modelu opartego o dwie zmienne wyszedł najniższy(16553.66).

Analiza wariancji

W analizie wariancji bedziemy zajmować się modelami zależnymi od czynników typu factor. Najpierw znajdziemy najbardziej znaczącą zmienną i zbudujemy model, który uwzględnia tylko ją. Następnie będziemy dołączać kolejne cechy i zobaczymy który model jest najlepszy.

Sprawdzimy to przyglądając się wykresom pudełkowym, obrazującym zależność wartości zmiennych typu factor a kosztem leczenia.

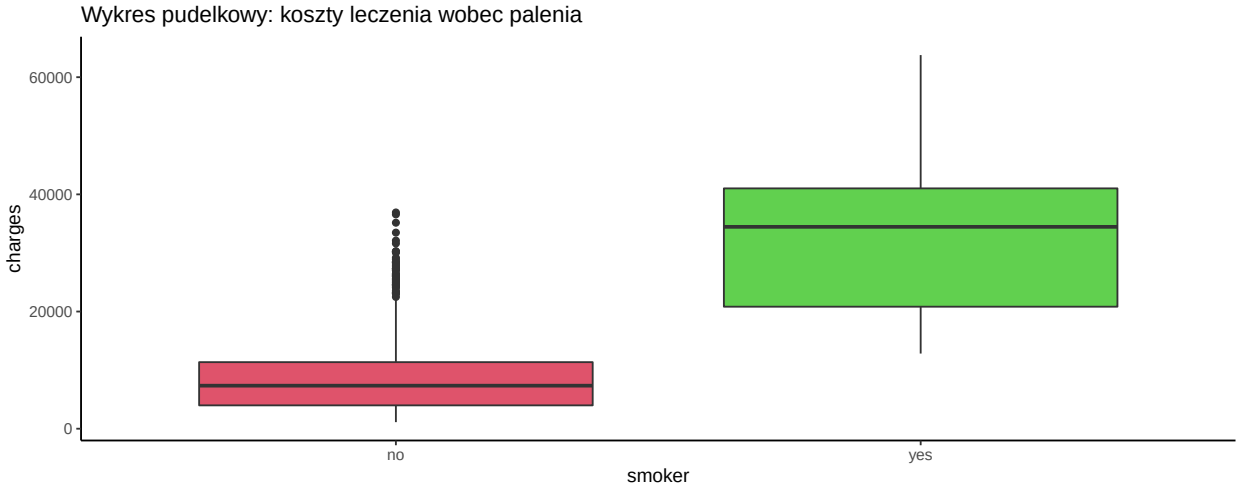

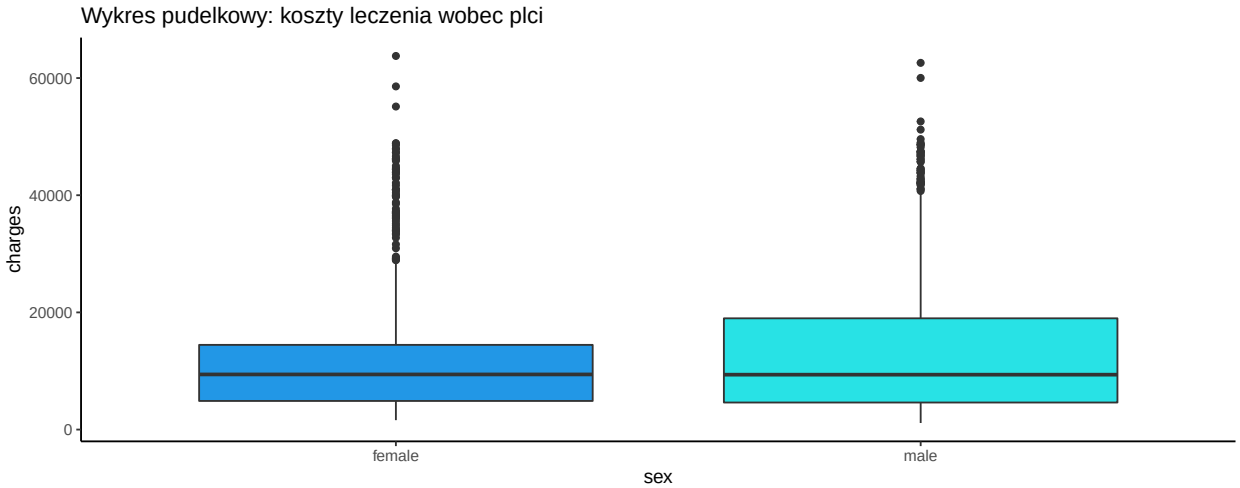

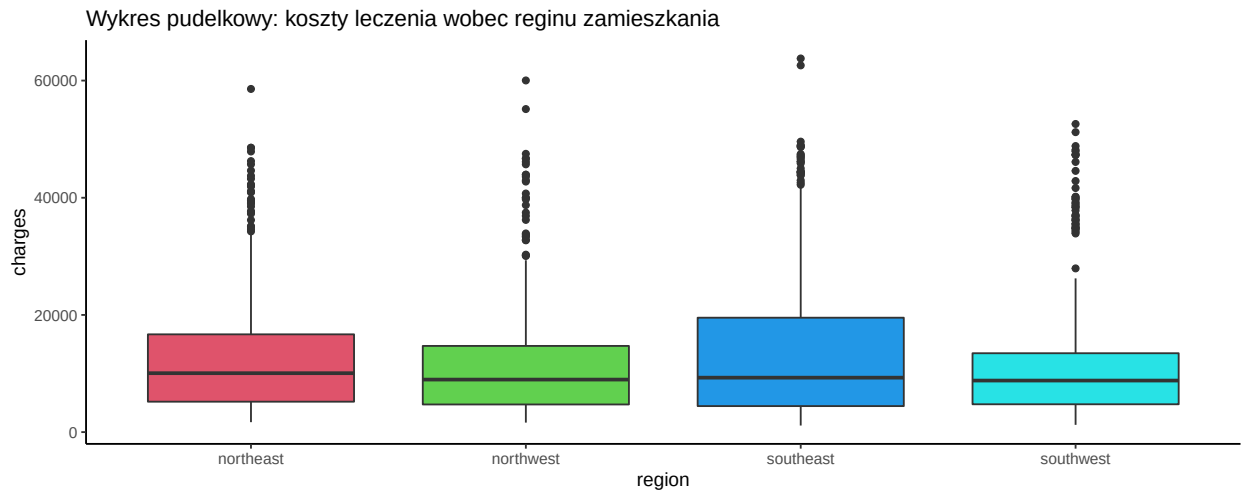

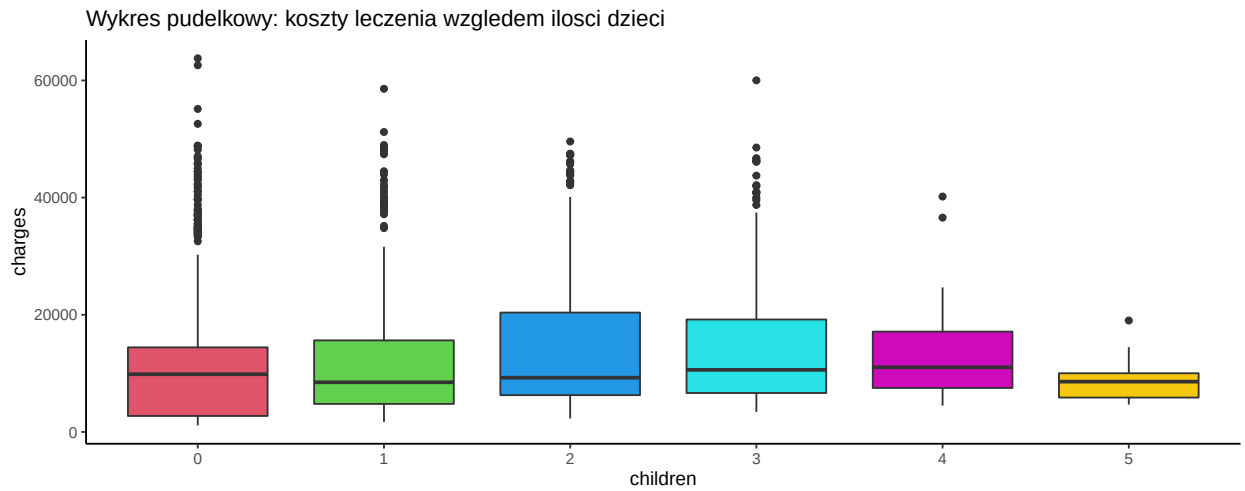

Widzimy, że najistotniejszym czynnikiem jest zmienna smoker. U palaczy, koszty ubezpieczenia są zwykle większe. Miejsce zamieszkania i płeć wydają się nie mieć wpływu na wysokość opłat za ubezpieczenie. Natomiast ilość dzieci osoby ubezpieczającej się, może być istotna.

Model z jednym czynnikiem: zmienną smoker.

```
one.way <- aov(charges ~ smoker, data = train)
summary(one.way)
```

```
##              Df    Sum Sq   Mean Sq F value Pr(>F)
## smoker        1 8.382e+10 8.382e+10    1474 <2e-16 ***
## Residuals   881 5.011e+10 5.687e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Im większa wartość F, tym większe prawdopodobieństwo, że zmienność spowodowana przez zmienną niezależną smoker nie jest przypadkowa. W tym przypadku jest całlkiem duża, to dobrze. Wartość p zmiennej smoker jest niska (p <0,001), więc wydaje się, że palenie ma wpływ na cenę ubezpieczenia.

Największy wpływ na opłaty za ubezpieczenie (oprócz zmiennej smoker) ma jednak zmienna children, sprawdźmy więc model uwzględniający ilość dzieci i indykator palenia.

```r
summary(aov(charges ~ smoker + children, data = train))
```

```
##              Df    Sum Sq   Mean Sq  F value  Pr(>F)
## smoker        1 8.382e+10 8.382e+10 1495.721 < 2e-16 ***
## children      5 1.013e+09 2.026e+08    3.615 0.00305 **
## Residuals   876 4.909e+10 5.604e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
two.way <- aov(charges ~ smoker + children, data = train)
```

Model wydaje sie być prawie tak samo dobry, jak ten z samą zmienną smoker.

Zbudujmy też model zależny od wszystkich zmiennych aby móc go później porównać z pozostałymi modelami, ale prawdopodobnie nie będzie on lepszy od poprzedniego.

```r
summary(aov(charges ~ smoker + children + sex + region, data = train))
```

```
##              Df    Sum Sq   Mean Sq  F value  Pr(>F)
## smoker        1 8.382e+10 8.382e+10 1496.389 < 2e-16 ***
## children      5 1.013e+09 2.026e+08    3.616 0.00304 **
## sex           1 1.502e+06 1.502e+06    0.027 0.86997
## region        3 2.445e+08 8.149e+07    1.455 0.22550
## Residuals   872 4.885e+10 5.602e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
all.way <- aov(charges ~ smoker + children + sex + region, data = train)
```

Możemy też sprawdzić model, w którym liczba dzieci jest zależna od tego czy osoba ubezpieczająca się jest palaczem.

```r
summary(aov(charges ~ smoker * children, data = train))
```

```
##                  Df    Sum Sq   Mean Sq  F value  Pr(>F)
## smoker            1 8.382e+10 8.382e+10 1497.611 < 2e-16 ***
## children          5 1.013e+09 2.026e+08    3.619 0.00302 **
## smoker:children   5 3.418e+08 6.836e+07    1.221 0.29697
## Residuals       871 4.875e+10 5.597e+07
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
interaction <- aov(charges ~ smoker * children, data = train)
```

Wybór modelu: Sprawdzamy AIC dla wszystkich modeli:

```r
extractAIC(one.way)[2]
```

```
## [1] 15769.15
```

```r
extractAIC(two.way)[2]
```

```
## [1] 15761.12
```

```r
extractAIC(all.way)[2]
```

```
## [1] 15764.68
```

```r
extractAIC(interaction)[2]
```

```
## [1] 15764.95
```

Model z jedną zmienną smoker jest najlepiej dopasowany. Ma on najniższą wartość AIC. To wydaję się być bardzo sensowne, biorąc pod uwage wykresy pudełkowe, wartości p, F i inne wartości modeli.

Analiza kowariancji

Będziemy wyjaśniać zmienną charges za pomocą zmiennych zarówno numerycznych jak i kategorycznych.

Wiemy już, że zmienne kategoryczne które warto wziąć pod uwagę to tylko zmienna smoker.

Na początku sprawdźmy model biorący pod uwagę wszytskie predyktory.

```r
model.lm.all <- lm(formula = charges ~ ., data = train)
summary(model.lm.all)
```

```
##
## Call:
## lm(formula = charges ~ ., data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11932.2  -3039.2   -958.2   1756.0  30083.3
##
## Coefficients:
##                  Estimate Std. Error t value Pr(>|t|)
## (Intercept)     -12489.68    1282.00  -9.742  < 2e-16 ***
## age               240.12      15.31  15.684  < 2e-16 ***
## sexmale          -278.64     425.64  -0.655  0.51288
## bmi               370.72      36.17  10.250  < 2e-16 ***
## children1         711.54     535.77   1.328  0.18451
## children2        1874.35     589.20   3.181  0.00152 **
## children3        1677.67     705.50   2.378  0.01762 *
## children4        4445.42    1473.25   3.017  0.00262 **
## children5        1781.88    1710.73   1.042  0.29789
## smokeryes       24158.12     516.65  46.760  < 2e-16 ***
## regionnorthwest  -538.76     603.78  -0.892  0.37248
## regionsoutheast  -940.41     609.60  -1.543  0.12327
## regionsouthwest  -1127.10    606.68  -1.858  0.06353 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 6249 on 870 degrees of freedom
## Multiple R-squared:  0.7463, Adjusted R-squared:  0.7428
## F-statistic: 213.3 on 12 and 870 DF,  p-value: < 2.2e-16
```

Widzimy że wartość p jest mała (<0.05) a więc możemy odrzucić hipoteze zerową tym samym przyjmując że może istnieć potencjalny związek między predyktorami a wynikiem. Niestety błąd standardowy jest bardzo duży (6249) przez odchylenie naszego modelu od lini regresji jest bardzo duże. Możemy to także zauważyć na poniższych wykresach.

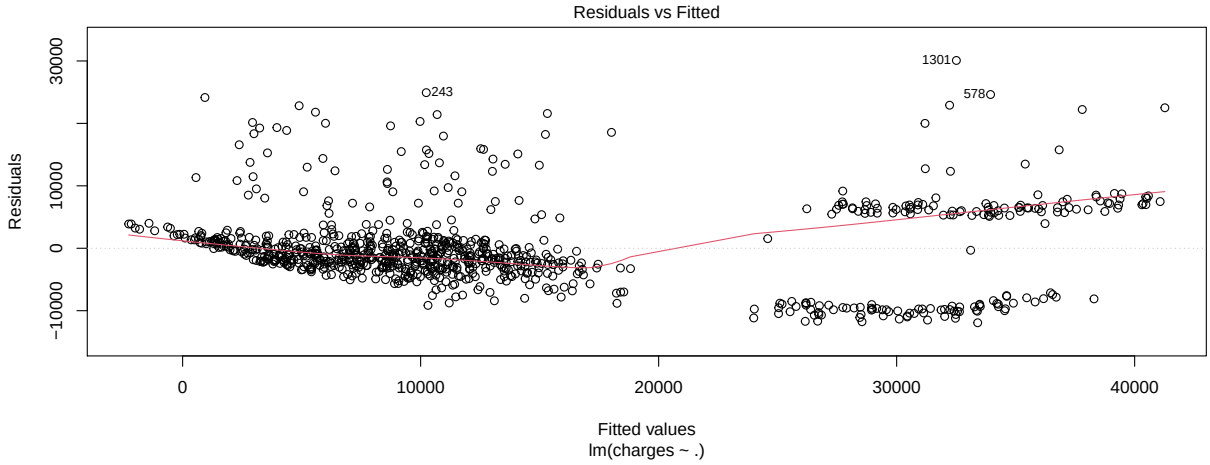

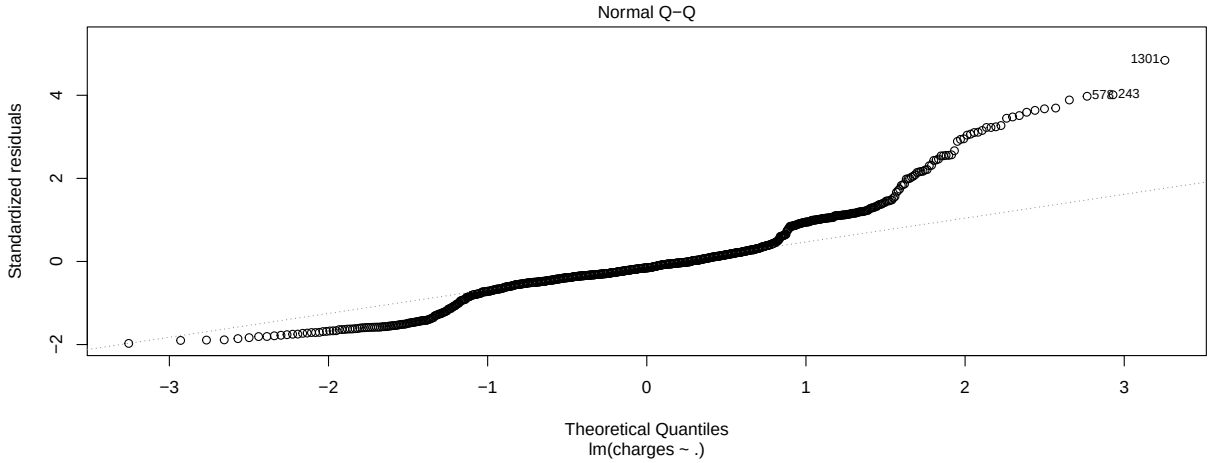

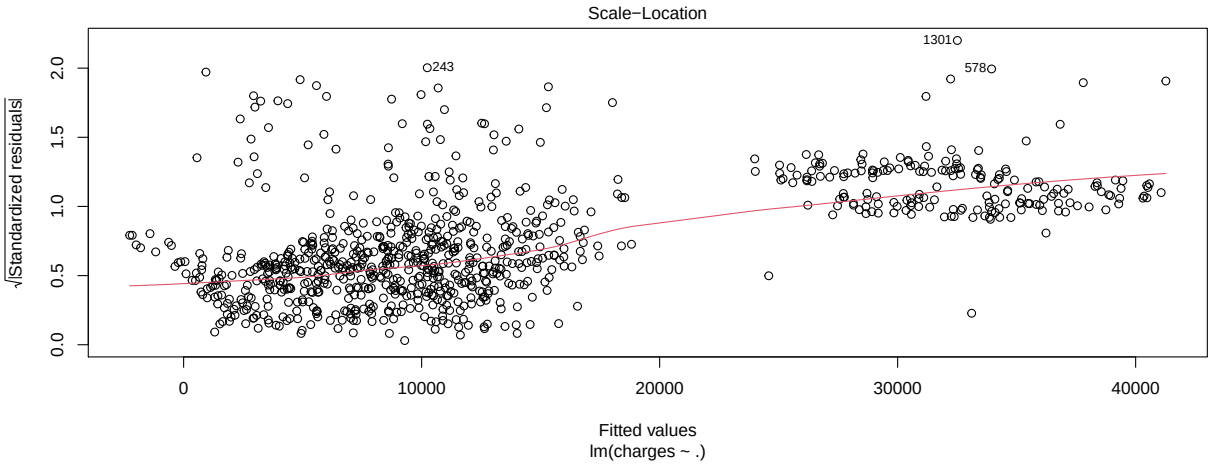

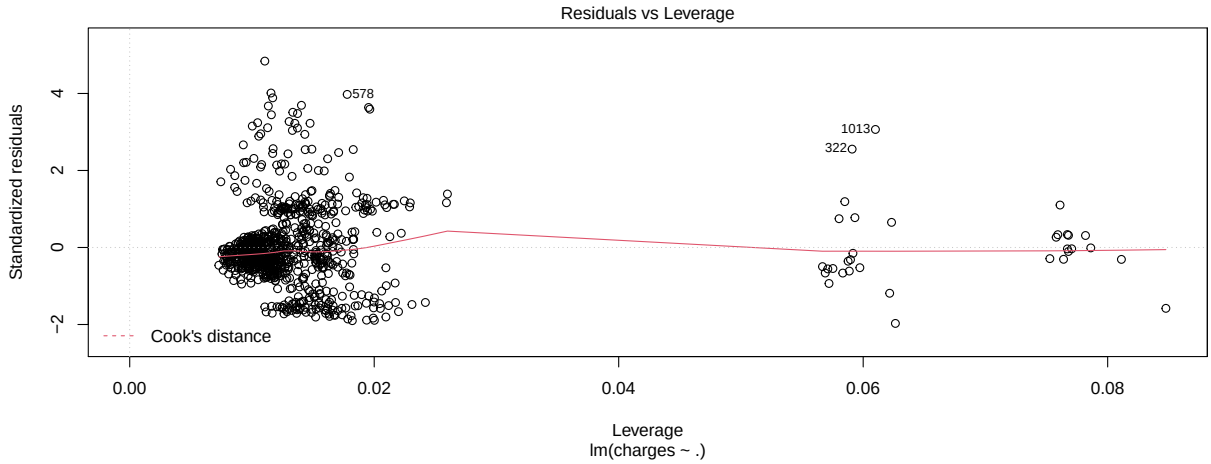

Zbudujmy teraz model zależny od następujących zmiennych: smoker - ponieważ budując modele ANOVA wyszło nam, że jest to jedyna cecha wpływająca znacząco na ostateczne opłaty za ubezpieczenie. bmi oraz age - ponieważ w modelach prostej i wielorakiej regresji wyszło, że są one istotne.

```
model.lm.sig <- lm(charges ~ age + bmi + smoker, data = train)
```

Wybór najlepszego modelu:

Podsumowując, ustaliliśmy, że biorąc pod uwagę zmienne kategoryczne, najlepszy model, to model one.way który wykorzystuje tylko zmienną smoker. W przypadku budowania modelu regresji, najlepszy był ten który uwzględniał zmienne age oraz bmi - model.age_bmi. Dzięki tym informacjom powstał model model.lm.sig, w którym opłaty za ubezpieczenie zależże są od wieku, bmi oraz faktu, czy osoba ubezpieczająca się pali.

Sprawdźmy jeszcze za pomocą AIC, czy ten model jest faktycznie najlepszy:

```
extractAIC(one.way)[2]
```

```
## [1] 15769.15
```

```r
extractAIC(model.age_bmi)[2]
```

```
## [1] 16553.66
```

```r
extractAIC(model.lm.sig)[2]
```

```
## [1] 15454.22
```

Ma najmniejsze AIC, więc prawdopodobnie będzie najlepszy do wykonania predykcji. Zobaczmy jego wykresy diagnostyczne:

```r
plot(model.lm.sig)
```

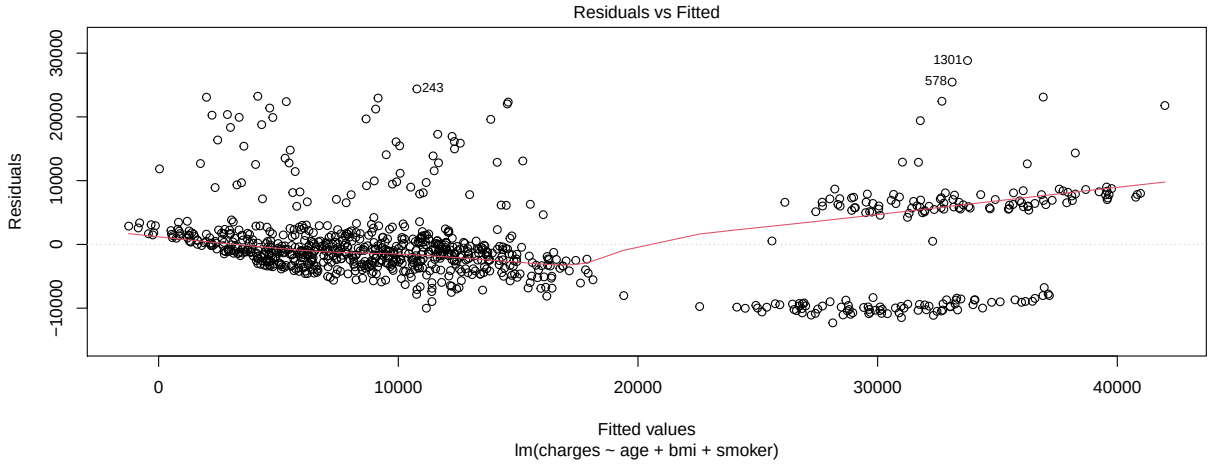

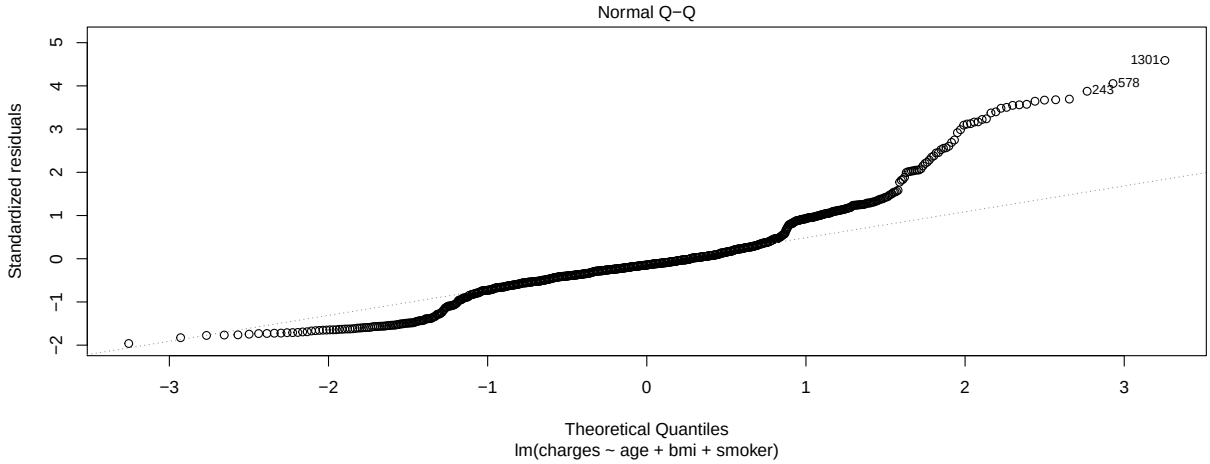

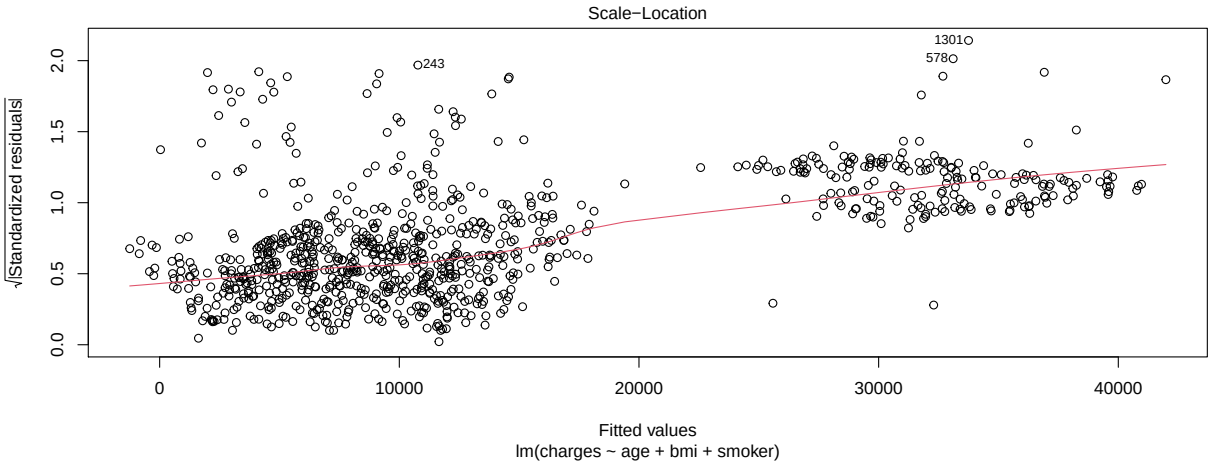

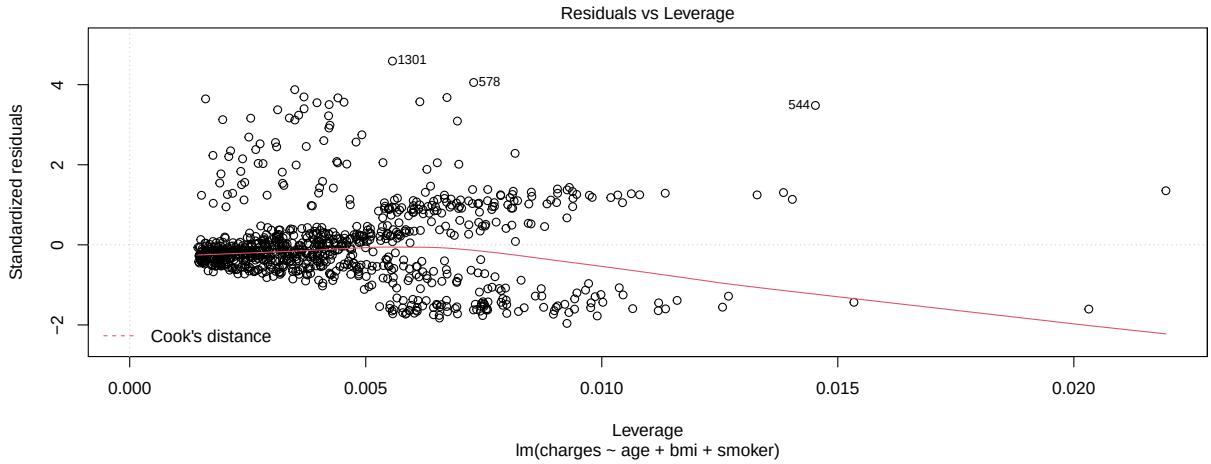

Widać, że wykresy diagnostyczne znacznie odbiegają od ideału. Próbowaliśmy więc różnych przekształceń danych, logarytmowaliśmy je oraz podnosiliśmy do potęgi, natomiast nic z tych rzeczy nie przyniosło oczekiwanego rezultatu, nawet jeśli model się poprawiał, to nieznacznie.

Sprawdźmy więc jak dla tego modelu będzie wyglądała predykcja.

Predykcja:

Z danych które będziemy testować usuwamy kolumne charges:

```
new.test <- test %>% select(-charges)
```

```
prediction <- predict(model.lm.sig, newdata = new.test)
```

Kilka pierwszych wyników predykcji:

```
head(prediction)
```

```
##          1          3          4          7         12         14
## 26583.776  6442.038  3995.895 10955.366 36420.477 15641.912
```

Dla porównania, prawdziwe dane:

```
head(test$charges)
```

```
## [1] 16884.924  4449.462 21984.471  8240.590 27808.725 11090.718
```

Na pierwszy rzut oka widać, że nie są one nawet za bardzo podobne.

Spróbujmy to jeszcze zwizualizować na wykresie: Na osi x umieścimy przewidywaną wartość, a na osi y realną. W idealnym modelu wszytskie wartości leżałyby na prostej x=y.

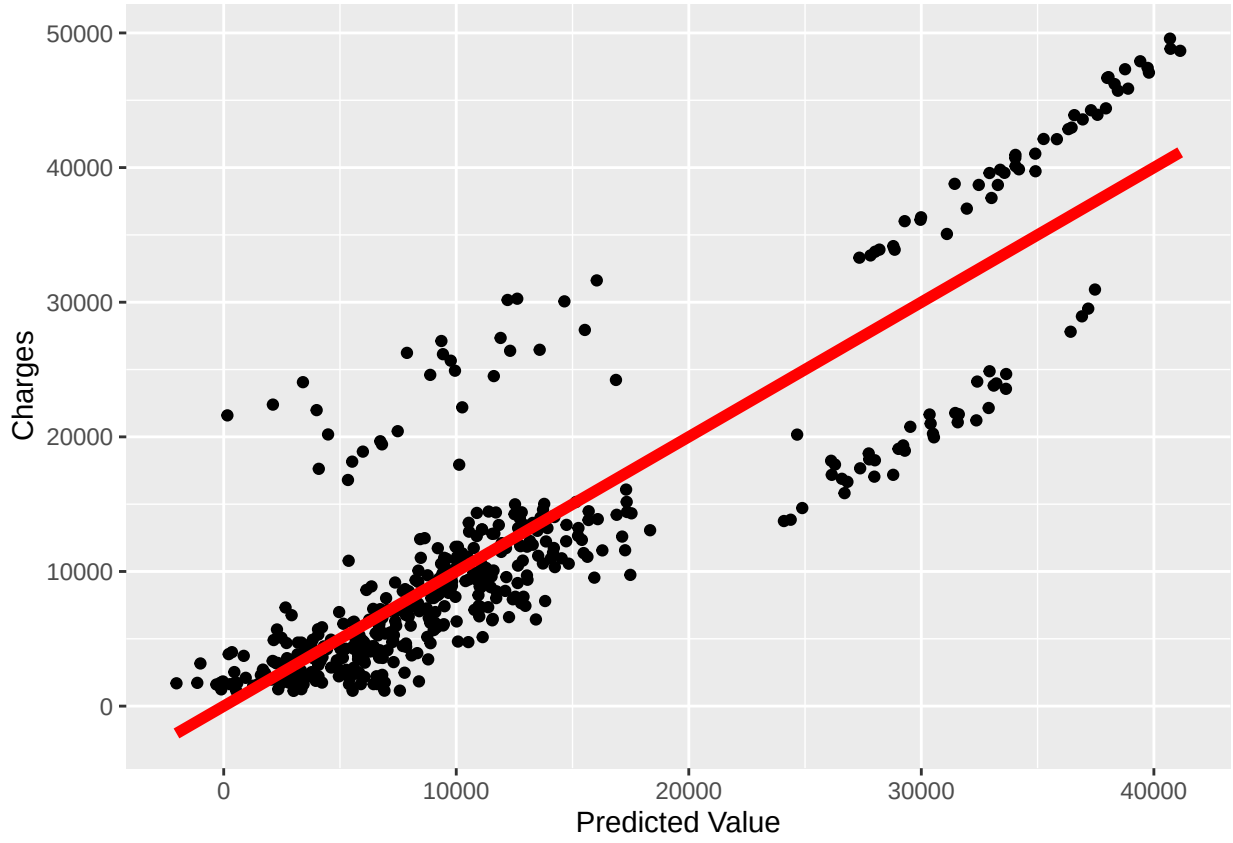

Wniosek:

Mimo sprawdzania wielu modeli, nasz model regresji a w związku z tym i predykcja nie są idealne. Próbowaliśmy też wielu innych modeli (przekształcenia zmiennych np logarytmem) ale nie przynosiło to oczekiwanych rezultatów, dane poprawiały się nieznacznie albo wcale.